

Homework 3

肖飞宇 2018210441

1 DIMENSION REDUCTION, PCA

1.1 Minimum Error Formulation

Proof. 对于 R^p 空间存在正交基,

$$\{\mu_i\}, i = 1, \dots, p \quad \mu_i^\top \mu_j = \delta_{ij} \quad (1.1)$$

那么每一个数据点都可以被表示为

$$\mathbf{x}_n = \sum_{i=1}^d \alpha_{ni} \mathbf{u}_i \quad (1.2)$$

那么在 R^D 空间中近似($D < p$), 即

$$\tilde{\mathbf{x}}_n = \sum_{i=1}^d z_{ni} \mu_i + \sum_{i=d+1}^p b_i \mu_i \quad (1.3)$$

其中的系数 z_{ni} 和数据 x_n 有关, 问题就转化为选取合适的参数, 使得下面的目标函数最小 (这就是 Minimum Error Formation) :

$$J = \frac{1}{N} \sum_{n=1}^N \|\mathbf{x}_n - \tilde{\mathbf{x}}_n\|^2 \quad (1.4)$$

将 $\tilde{\mathbf{x}}_n$ 代入上式, 得到

$$J = \frac{1}{N} \sum_{n=1}^N \left(X_n - \sum_{i=1}^d z_{ni} \mu_i - \sum_{i=d+1}^p b_i \mu_i \right)^T \left(X_n - \sum_{i=1}^d z_{ni} \mu_i - \sum_{i=d+1}^p b_i \mu_i \right) \quad (1.5)$$

$$= \frac{1}{N} \sum_{n=1}^N \left(x_n^T x_n - 2x_n^T \left(\sum_{i=1}^d z_{ni} \mu_i + \sum_{i=d+1}^p b_i \mu_i \right) + \sum_{i=1}^d z_{ni}^2 + \sum_{i=d+1}^p b_i^2 \right) \quad (1.6)$$

上式对 z_{ni} 求导有

$$\frac{1}{N}(-2x_n^T \mu_i + 2z_{ni}) = 0 \quad (1.7)$$

得

$$z_{ni} = \mathbf{x}_n^T \mu_i, i = 1, \dots, d \quad (1.8)$$

对 b_i 求导有

$$\frac{1}{N}(-2x_n^T \mu_i) + 2b_i = 0 \quad (1.9)$$

得到

$$b_i = \bar{\mathbf{x}}^T \mu_i, i = d + 1, \dots, p \quad (1.10)$$

□

1.2 MNIST

算法

具体的 PCA 算法的实现见

<https://github.com/feiyuxiaoThu/SML/blob/master/Assigenments/Assignment3-PCA-Mnist/MnistPCA.py>.

结果

选定数字0和1进行说明，其结果分别如图1.1和图1.2所示




Figure 1.1: 数字0




Figure 1.2: 数字1




Figure 1.3: Dimension and Information

可以将使用的近似维度和准确程度的关系绘制如图1.3：对于数据不进行中心化的情况，其结果如图1.4和图1.5所示，可以看出不进行中心化结果的噪声非常严重，造成精确度严重下降

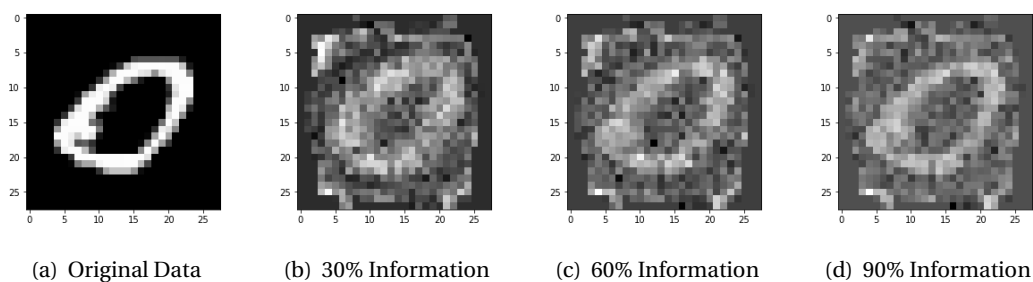


Figure 1.4: 数字0（未中心化）




Figure 1.5: 数字1（未中心化）

2 LEARNING THEORY

2.1 VC Dimension

Proof. 首先不是所有四个点的集合都可以被打散，如下图2.1(1)中的组合就不可以被打散，但这并不足以说明VC-dimension至多是3，如图2.1(2)所示，显然可以有一个矩形包含任意给定的点集而不包含其他，所以我们可以得到VC-dimension至少是4。再考察任意五个不同的点的集合 $\{v_1, v_2, v_3, v_4, v_5\} \subseteq \mathbb{R}^2$ ，如图2.1(3)所示，考虑一个矩形包含了集合中最大的x,最大的y, 最小的x, 最小的y坐标的点（这些点并不需要不同，但是至多有四个），这些点记为 $S \subset \{v_1, v_2, v_3, v_4, v_5\}$ 。可以看出，任何包含了S的矩形一定会包含全部的点 v_1, v_2, v_3, v_4, v_5 ，即至多有一个点不在S中，但是一定在矩形中，记为 v_w 。只需要把S中的点标注为+而把 v_w 标注为-就不可能被打散，可以说明VC-dimension小于5。

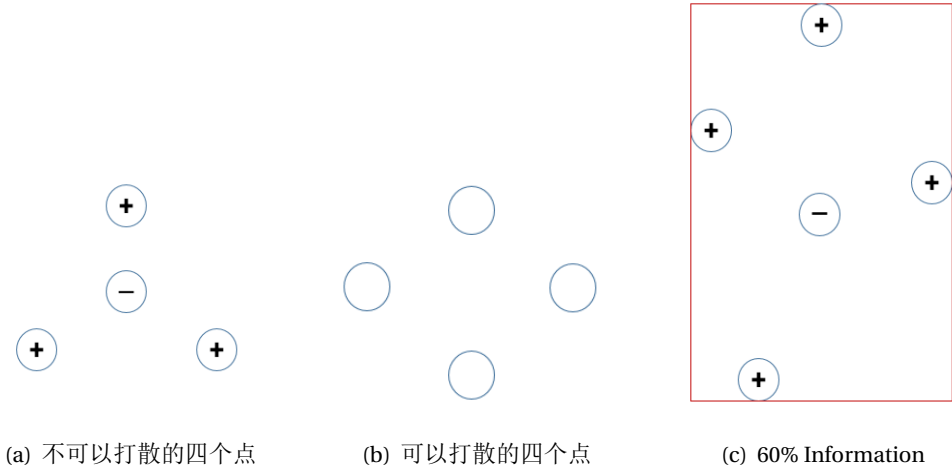


Figure 2.1: VC-dimension示意图

□

2.2 Generalization Bound

Proof. 我们首先计算 $H = \{(a < x < b) | a, b \in R\}$ 的 $m_{\mathcal{H}}(N)$ ，注意到对给定的N个点，数轴被分割成N+1个区域，显然最终的结果取决于a,b所处的区间的位置，这就有 $\binom{N+1}{2}$ 种结果，另外，如果a,b在同一个区间，那么最终的结果就是全是-1。把这两种情况一起考虑可以得到：

$$m_{\mathcal{H}}(N) = \binom{N+1}{2} + 1 = \frac{1}{2}N^2 + \frac{1}{2}N + 1 \quad (2.1)$$

再使用Vapnik-Chervonenkis不等式，有

$$P[|E_{in} - E_{out}| > \epsilon] \leq 4m_{\mathcal{H}}(2N)e^{-\frac{1}{8}\epsilon^2 N} \quad (2.2)$$

$$= (8N^2 + 8N + 4)e^{-\frac{1}{8}\epsilon^2 N} \quad (2.3)$$

□

3 REINFORCEMENT LEARNING

3.1 'Vanilla' Policy Gradient

Proof. 首先，我们的目标函数为：

$$J(\theta) = E_{\tau \sim P(\tau; \theta)} \left(\sum_t r(s_t, a_t) \right) = E_{\tau \sim P(\tau; \theta)} (R(\tau)) \quad (3.1)$$

根据期望的定义有

$$J(\theta) = \int p_\theta(\tau) R(\tau) d\tau \quad (3.2)$$

其梯度为

$$\nabla_\theta J(\theta) = \int \nabla_\theta p_\theta(\tau) R(\tau) d\tau \quad (3.3)$$

由链式求导法则有

$$p_\theta(\tau) \nabla_\theta \log p_\theta(\tau) = p_\theta(\tau) \frac{\nabla_\theta p_\theta(\tau)}{p_\theta(\tau)} = \nabla_\theta p_\theta(\tau) \quad (3.4)$$

将上式代入方程3.3，有

$$\nabla_\theta J(\theta) = \int p_\theta(\tau) \nabla_\theta \log p_\theta(\tau) R(\tau) d\tau = E_{\tau \sim p_\theta(\tau)} [\nabla_\theta \log p_\theta(\tau) R(\tau)] \quad (3.5)$$

而又已知

$$p(\tau; \theta) = p(s_1) \prod_t \pi_\theta(a_t | s_t) p(s_{t+1} | s_t, a_t) \quad (3.6)$$

两边取对数有

$$\log p(\tau; \theta) = \log p(s_1) + \sum_{t=1}^T [\log \pi_\theta(a_t | s_t) + \log p(s_{t+1} | s_t, a_t)] \quad (3.7)$$

注意到 $\nabla_\theta \log p_\theta(\tau)$ 仅与含有 θ 的项有关，知其导数为

$$\nabla_\theta \log p(\tau; \theta) = \sum_{t=1}^T \nabla_\theta \log \pi_\theta(a_t | s_t) \quad (3.8)$$

代入方程3.5得到：

$$\nabla_\theta J(\theta) = E_{\tau \sim P(\tau; \theta)} \left(\sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) R(\tau) \right) \quad (3.9)$$

□

3.2 Actor-Critic

Proof. 引入一个baseline函数 $B(s)$ ，则有

$$\nabla_\theta J(\theta) = E_{\pi_\theta} [\nabla_\theta \log \pi_\theta(s, a) (Q^{\pi_\theta}(s, a) - B(s))] \quad (3.10)$$

计算

$$\mathbb{E}[\nabla_{\theta} \log P(\tau; \theta) B(s)] = \sum_{\tau} P(\tau; \theta) \nabla_{\theta} \log P(\tau; \theta) B(s) \quad (3.11)$$

$$= \sum_{\tau} P(\tau; \theta) \frac{\nabla_{\theta} P(\tau; \theta)}{P(\tau; \theta)} B(s) \quad (3.12)$$

$$= \sum_{\tau} \nabla_{\theta} P(\tau; \theta) B(s) \quad (3.13)$$

$$= \nabla_{\theta} \left(\sum_{\tau} P(\tau) B(s) \right) \quad (3.14)$$

$$= B(s) \nabla_{\theta} \left(\sum_{\tau} P(\tau) \right) = 0 \quad (3.15)$$

可以看出不改变原有的期望,而对于 critic 算法

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(s, a) (R(\tau) - B(s))] \quad (3.16)$$

$$= \mathbb{E}_{\pi_{\theta}} \left(\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) \left(\sum_t r(s_t, a_t) - B(s) \right) \quad (3.17)$$

$$= \mathbb{E}_{\pi_{\theta}} \left(\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) \left(\underbrace{\sum_{k=0}^{t-1} r(s_t, a_t)}_{\mathbb{A}} + \underbrace{\sum_{k=t} r(s_t, a_t)}_{\mathbb{B}} - B(s) \right) \quad (3.18)$$

上式中 \mathbb{A} 和 a_t 无关,所以可以去掉减小方差,所以最后给出的估计是

$$\mathbb{E}_{\pi_{\theta}} \left(\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right) \left(\sum_{k=t} r(s_t, a_t) - B(s) \right) \quad (3.19)$$

□